Индивидуальный цифровой проект

Системы искусственного интеллекта 1 курс 2 сем:

	Задания	Итерации	Баллы
1)	Самостоятельная работа (07.03)		5
2)	Обзор датасета	Итерация 1	20
3)	Проект: «Исследование датасета»	Итерация 2	10
4)	Защита проекта (04.04)		15
5)	Визуализация данных	Итерация 3	10
6)	Доп баллы: GitHub репозиторий проекта		10

Автомат на зачете: >55 баллов

«Максимум» на зачете: >60 баллов

Обзор датасета:

Необходимо выбрать **численный** набор данных с ресурса *Kaggle*. Для этого набора данных необходимо привести текстовое описание:

- Источник данных (кто собрал, в каком контексте, для какой цели);
- Структура данных (формат, колонки, тип значений, примеры данных);
- Потенциал использования (т.е. для каких задач может быть применим набор данных).

Описание проекта:

1) Загрузка и первичная обработка данных:
   - Загрузить датасет с помощью pandas.
   - Вывести первые и последние строки таблицы.
   - Необходимо определить:
     - Размер датасета (количество строк и столбцов);
     - Типы данных;
     - Наличие пропущенных значений.
2) Очистка данных
   - Найти пропущенные значения (если таких нет, то добавить искусственно -- случайным образом).
   - Обработать их (удалить или заполнить, обосновать выбор).
   - Проверить наличие дубликатов.
   - При необходимости привести типы данных к корректному виду.

3) Базовый анализ данных
   - Рассчитать основные статистические показатели по столбцам:
     - Среднее значение;

    - Медиану;
    - Минимум и максимум;
    - Стандартное отклонение.
- Рассчитать баланс классов (если есть).
- Построить группировку по одному или нескольким признакам (*groupby*).
- Определить:
    - Наиболее часто встречающиеся категории;
    - Топ-5 значений по выбранному критерию.

4) Сформулировать вывод о наборе данных:
   - Какие столбцы наиболее важные?
   - Какие закономерности можно выявить без применения методов машинного обучения?

<u>Визуализация данных:</u>

В соответствии с выбранным датасетом необходимо построить ряд графиков:

1) Построить гистограммы (распределение числового признака) для двух числовых столбцов.
2) Построить столбчатую диаграмму для категориального признака.
3) Построить круговую диаграмму для категориального признака.
4) Построить линейный график для любого признака => отобразить динамику.
5) Построить сравнительную столбчатую диаграмму для нескольких признаков (признаки должны быть измеримы по одной шкале, например: оценки, деньги в одной валюте и др).

К каждому графику должны быть подпись и краткий вывод.